Random Forest - Forêt Aléatoire

Théorie

La forêt aléatoire est un algorithme d'apprentissage supervisé basé sur un ensemble d'arbres de décision. Il fonctionne en combinant plusieurs arbres pour améliorer la précision et réduire le risque de surapprentissage.

Hyperparamètre utilisé

Nous allons optimiser:

• Nombre d'arbres (n_estimators) : sélectionné en fonction de la précision sur l'ensemble de validation.

Métriques d'évaluation

Nous afficherons:

- Matrice de confusion : récapitulant les erreurs de classification.
- Taux de bien classés sur l'échantillon de validation avec le meilleur hyperparamètre.
- Taux de bien classés sur l'échantillon de test avec ce même hyperparamètre.
- Taux de bien classés par classe sur l'échantillon de test.

Recherche du meilleur n_estimators et évaluation

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import confusion_matrix, accuracy_score
import warnings

# Suppression des avertissements inutiles
warnings.filterwarnings("ignore", category=UserWarning)

# Chargement des ensembles de données
```

```
train_data = pd.read_csv('../data/covertype_train.csv')
val_data = pd.read_csv('../data/covertype_val.csv')
test_data = pd.read_csv('../data/covertype_test.csv')
# Préparation des données
X_train, y_train = train_data.drop('Cover_Type', axis=1),
+ train_data['Cover_Type']
X_val, y_val = val_data.drop('Cover_Type', axis=1),

    val_data['Cover_Type']

X_test, y_test = test_data.drop('Cover_Type', axis=1),

    test_data['Cover_Type']

# Recherche du meilleur hyperparamètre n_estimators
n_estimators_range = range(50, 1000, 50)
val_accuracies = []
for n in n_estimators_range:
   rf = RandomForestClassifier(n_estimators=n, random_state=42,
 \rightarrow n_jobs=-1)
   rf.fit(X_train, y_train)
    acc = accuracy_score(y_val, rf.predict(X_val))
   val_accuracies.append((n, acc))
# Sélection du meilleur nombre d'arbres
best_n, best_val_acc = max(val_accuracies, key=lambda x: x[1])
# Affichage du graphique
plt.figure(figsize=(8, 6))
plt.plot(n_estimators_range, [acc for n, acc in val_accuracies],
→ marker='o', linestyle='dashed', label="Validation")
plt.xlabel("Nombre d'arbres")
plt.ylabel("Précision sur validation")
plt.title("Impact du nombre d'arbres sur la performance de Random
→ Forest")
plt.legend()
plt.show()
# Modèle final avec le meilleur nombre d'arbres
final_model = RandomForestClassifier(n_estimators=best_n,

¬ random_state=42, n_jobs=-1)

final_model.fit(X_train, y_train)
y_test_pred = final_model.predict(X_test)
# Matrice de confusion
conf_matrix = confusion_matrix(y_test, y_test_pred)
```

```
# Calcul des taux de bien classés par classe
class_accuracies = conf_matrix.diagonal() /

    conf_matrix.sum(axis=1)

overall_test_accuracy = accuracy_score(y_test, y_test_pred)
  Affichage des résultats
print(f"\n Meilleur nombre d'arbres sur l'échantillon de

    validation : {best_n}")

print(f"Taux de bien classés sur l'échantillon de validation avec

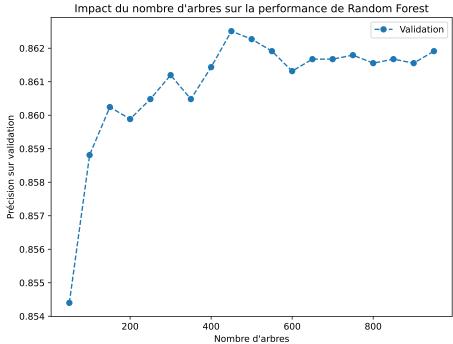
    cet hyperparamètre : {best_val_acc:.2%}")

print("\n Matrice de confusion sur l'échantillon de test, avec le
 → meilleur hyperparamètre :")
print(conf_matrix)
print("\n Taux de bien classés par classe sur l'échantillon de

    test, avec le meilleur hyperparamètre :")

for i, acc in enumerate(class_accuracies, start=1):
    print(f"Classe {i} : {acc:.2%}")
print(f"\n Taux de bien classés sur l'échantillon de test avec le
 → meilleur hyperparamètre : {overall_test_accuracy:.2%}")
           Impact du nombre d'arbres sur la performance de Random Forest

    Validation
```



Meilleur nombre d'arbres sur l'échantillon de validation : 450 Taux de bien classés sur l'échantillon de validation avec cet hyperparamètre : 86.25%

 ${\tt Matrice\ de\ confusion\ sur\ l'échantillon\ de\ test,\ avec\ le\ meilleur\ hyperparamètre}:$

[[1	L753	312	0	0	5	2	47]
	247	2490	40	1	20	31	4]
	0	15	1352			51	0]
	0	0	37	. –	0	2	0]
	3	86	16	0	273	2	0]
	1	17	128	2	0	546	0]
[43	4	0	0	0	0	774]]

Taux de bien classés par classe sur l'échantillon de test, avec le meilleur hyperparamètre

Classe 1 : 82.73% Classe 2 : 87.89% Classe 3 : 94.55% Classe 4 : 64.55% Classe 5 : 71.84% Classe 6 : 78.67% Classe 7 : 94.28%

Taux de bien classés sur l'échantillon de test avec le meilleur hyperparamètre : 86.55%