Bienvenue!

Ce cours explore différentes méthodes de Machine Learning pour la classification supervisée, c'est-à-dire l'affectation d'individus à des catégories discrètes (targets) en fonction de variables explicatives (features), qu'elles soient continues ou catégorielles.

L'objectif est de comparer les performances de ces méthodes en évaluant :

- Leur précision globale sur l'ensemble des classes
- Leur capacité à bien prédire les classes les plus rares, souvent les plus difficiles à classifier.

Le dataset utilisé : Covertype

Nous utilisons le **dataset Covertype**, issu de l'UCI Machine Learning Repository. Ce jeu de données comprend :

- 581 012 observations
- 54 variables explicatives
- 7 classes différentes représentant des types de couvertures forestières

Les classes sont fortement **déséquilibrées numériquement**, ce qui constitue un défi supplémentaire pour les modèles de classification.

Objectifs du cours

Nous expérimenterons plusieurs approches, notamment :

- Méthodes paramétriques : régression logistique, LDA, QDA...
- Méthodes non-paramétriques : KNN, arbres de décision, forêts aléatoires...
- Modèles à base de réseaux de neurones
- Stratégies One-Versus-All (OVA) et One-Versus-One (OVO) pour les modèles binaires

Ce cours vise ainsi à comparer l'efficacité de ces différentes méthodes et à identifier celles qui offrent les meilleurs compromis en termes de précision, robustesse et adaptation aux déséquilibres de classe.