Analyse Discriminante Quadratique (QDA) - Multiclasse

Théorie

L'**Analyse Discriminante Quadratique (QDA)** est une technique de classification qui, contrairement à LDA, permet aux classes d'avoir des **matrices de covariance différentes**. Cela le rend plus flexible mais peut aussi augmenter le risque de sur-apprentissage.

Contrairement à d'autres modèles initialement conçus pour des problèmes binaires et adaptés aux cas multiclasse via OVA ou OVO, **QDA est intrinsèquement multiclasse**. Il attribue directement une observation à l'une des classes disponibles en estimant des distributions normales multivariées et en utilisant la règle de Bayes.

Hyperparamètre utilisé

Nous allons optimiser :

- **Régularisation (`reg_param`)** : contrôle la variance de la covariance estimée et est sélectionnée en fonction de la précision sur l'ensemble de validation.

Métriques d'évaluation

Nous afficherons :

- **Matrice de confusion** : montrant les erreurs de classification sur l'échantillon de test.
- **Taux de bien classés sur l'échantillon de validation** avec le meilleur hyperparamètre.
- **Taux de bien classés sur l'échantillon de test** avec ce même hyperparamètre.
- **Taux de bien classés par classe sur l'échantillon de test** pour observer la précision sur chaque classe.

Recherche du meilleur reg_param et évaluation

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.discriminant_analysis import
 ↪  QuadraticDiscriminantAnalysis
from sklearn.metrics import confusion_matrix, accuracy_score
from sklearn.preprocessing import StandardScaler
import warnings

#  Suppression des avertissements inutiles
warnings.filterwarnings("ignore", category=UserWarning)

#  Chargement des ensembles de données
train_data = pd.read_csv('../data/covertype_train.csv')
val_data = pd.read_csv('../data/covertype_val.csv')
test_data = pd.read_csv('../data/covertype_test.csv')

#  Préparation des données
X_train, y_train = train_data.drop('Cover_Type', axis=1),
 ↪  train_data['Cover_Type']
X_val, y_val = val_data.drop('Cover_Type', axis=1),
 ↪  val_data['Cover_Type']
X_test, y_test = test_data.drop('Cover_Type', axis=1),
 ↪  test_data['Cover_Type']

#  Normalisation des données
scaler = StandardScaler()
X_train, X_val, X_test = scaler.fit_transform(X_train),
 ↪  scaler.transform(X_val), scaler.transform(X_test)

#  Recherche du meilleur hyperparamètre reg_param
reg_params = np.linspace(0, 1, 10)
val_accuracies = []

for reg_param in reg_params:
    qda = QuadraticDiscriminantAnalysis(reg_param=reg_param)
    qda.fit(X_train, y_train)
    acc = accuracy_score(y_val, qda.predict(X_val))
    val_accuracies.append((reg_param, acc))

# Sélection du meilleur hyperparamètre
best_reg_param, best_val_acc = max(val_accuracies, key=lambda x:
 ↪  x[1])

#  Affichage du graphique
```

```
plt.figure(figsize=(8, 6))
plt.plot(reg_params, [acc for reg_param, acc in val_accuracies],
 ↪  marker='o', linestyle='dashed', label="Validation")
plt.xlabel("Régularisation (reg_param)")
plt.ylabel("Précision sur validation")
plt.title("Impact de la régularisation sur la performance de
 ↪  QDA")
plt.legend()
plt.show()

#  Modèle final avec le meilleur hyperparamètre
final_model =
 ↪  QuadraticDiscriminantAnalysis(reg_param=best_reg_param)
final_model.fit(X_train, y_train)
y_test_pred = final_model.predict(X_test)

#  Matrice de confusion
conf_matrix = confusion_matrix(y_test, y_test_pred)

#  Calcul des taux de bien classés par classe
class_accuracies = conf_matrix.diagonal() /
 ↪  conf_matrix.sum(axis=1)
overall_test_accuracy = accuracy_score(y_test, y_test_pred)

#  Affichage des résultats
print(f"\n  Meilleur hyperparamètre reg_param sur l'échantillon de
 ↪  validation : {best_reg_param:.2f}")
print(f"Taux de bien classés sur l'échantillon de validation avec
 ↪  cet hyperparamètre : {best_val_acc:.2%}")
print("\n  Matrice de confusion sur l'échantillon de test, avec le
 ↪  meilleur hyperparamètre :")
print(conf_matrix)

print("\n  Taux de bien classés par classe sur l'échantillon de
 ↪  test, avec le meilleur hyperparamètre :")
for i, acc in enumerate(class_accuracies, start=1):
    print(f"Classe {i} : {acc:.2%}")

print(f"\n  Taux de bien classés sur l'échantillon de test avec le
 ↪  meilleur hyperparamètre : {overall_test_accuracy:.2%}")
```

```
/home/ensai/.local/share/virtualenvs/postagram_ensai-i0XV5lHB/lib/python3.10/site-packages/s
  warnings.warn(
/home/ensai/.local/share/virtualenvs/postagram_ensai-i0XV5lHB/lib/python3.10/site-packages/s
  warnings.warn(
/home/ensai/.local/share/virtualenvs/postagram_ensai-i0XV5lHB/lib/python3.10/site-packages/s
  warnings.warn(
```

```
/home/ensai/.local/share/virtualenvs/postagram_ensai-i0XV5lHB/lib/python3.10/site-packages/s
  warnings.warn(
/home/ensai/.local/share/virtualenvs/postagram_ensai-i0XV5lHB/lib/python3.10/site-packages/s
  warnings.warn(
/home/ensai/.local/share/virtualenvs/postagram_ensai-i0XV5lHB/lib/python3.10/site-packages/s
  warnings.warn(
/home/ensai/.local/share/virtualenvs/postagram_ensai-i0XV5lHB/lib/python3.10/site-packages/s
  warnings.warn(
```

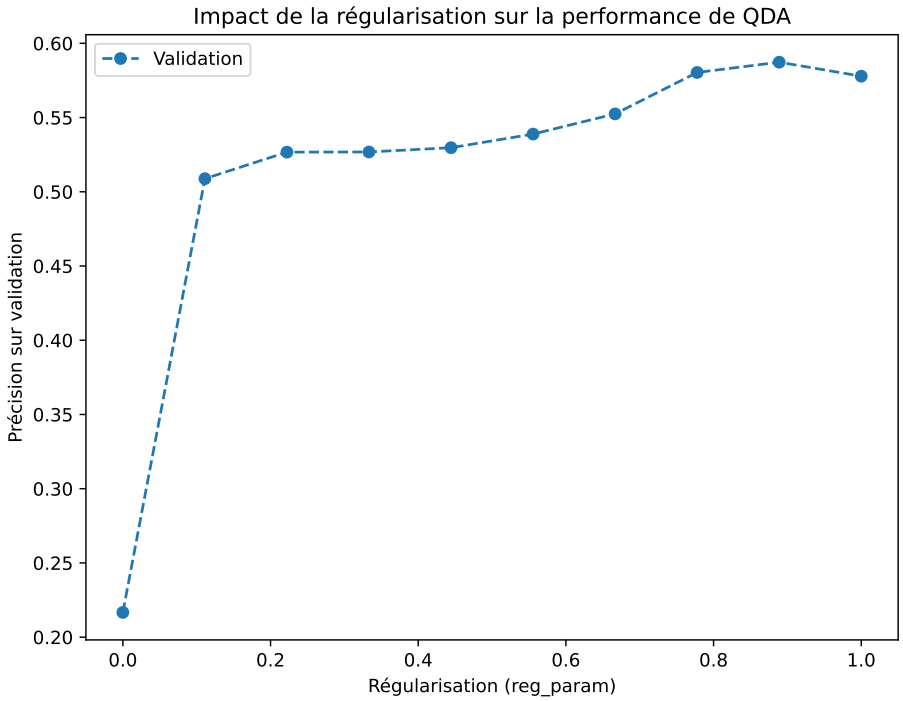


```
 Meilleur hyperparamètre reg_param sur l'échantillon de validation : 0.89
Taux de bien classés sur l'échantillon de validation avec cet hyperparamètre : 58.73%

 Matrice de confusion sur l'échantillon de test, avec le meilleur hyperparamètre :
[[1163  626    1    1   89   14  225]
 [ 650 1561   51   27  402  125   17]
 [   0    7  948  136   50  289    0]
 [   0    0   45   53    0   12    0]
 [  28  103   27   19  191   12    0]
 [  11   34  230   53   31  335    0]
 [ 103   35    3    0   16    0  664]]

 Taux de bien classés par classe sur l'échantillon de test, avec le meilleur hyperparamètre
```

```
Classe 1 : 54.88%
Classe 2 : 55.10%
Classe 3 : 66.29%
Classe 4 : 48.18%
Classe 5 : 50.26%
Classe 6 : 48.27%
Classe 7 : 80.88%

  Taux de bien classés sur l'échantillon de test avec le meilleur hyperparamètre : 58.60%
```