# Réseau de Neurones (MLP) avec sortie Softmax

## Théorie

Un réseau de neurones multi-couches (**MLP - Multi-Layer Perceptron**) est un modèle d'apprentissage supervisé basé sur des couches de neurones artificiels. Il est particulièrement efficace pour la classification non linéaire.

Dans notre cas, nous utilisons **une couche de sortie Softmax**, qui permet de normaliser les sorties du réseau en probabilités pour une classification multi-classes.

## Hyperparamètre utilisé

Nous allons optimiser :

- **Nombre d'époques (`epochs`)** : sélectionné en fonction de la précision sur l'ensemble de validation.

Nous utilisons également : - **Optimiseur Adam** avec un taux d'apprentissage adaptatif. - **Taille du batch (`batch_size`)** fixé à 32.

## Métriques d'évaluation

Nous afficherons :

- **Matrice de confusion** : montrant les erreurs de classification sur l'échantillon de test.
- **Taux de bien classés sur l'échantillon de validation** avec le meilleur nombre d'époques.
- **Taux de bien classés sur l'échantillon de test** avec ce même hyperparamètre.
- **Taux de bien classés par classe sur l'échantillon de test** pour observer la précision sur chaque classe.

## Recherche du meilleur nombre d'époques et évaluation

```
import os
import torch
```

```
import torch.nn as nn
import torch.optim as optim
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import warnings
from sklearn.metrics import confusion_matrix, accuracy_score
from sklearn.preprocessing import StandardScaler
from torch.utils.data import TensorDataset, DataLoader

#  Suppression des avertissements inutiles
warnings.filterwarnings("ignore", category=UserWarning)

#  Utilisation du CPU uniquement (désactivation GPU)
device = torch.device("cpu")
torch.backends.cudnn.enabled = False
os.environ["CUDA_VISIBLE_DEVICES"] = "-1"

#  Chargement des ensembles de données
train_data = pd.read_csv('../data/covertype_train.csv')
val_data = pd.read_csv('../data/covertype_val.csv')
test_data = pd.read_csv('../data/covertype_test.csv')

#  Préparation des données
X_train, y_train = train_data.drop('Cover_Type', axis=1).values,
 ↪  train_data['Cover_Type'].values - 1
X_val, y_val = val_data.drop('Cover_Type', axis=1).values,
 ↪  val_data['Cover_Type'].values - 1
X_test, y_test = test_data.drop('Cover_Type', axis=1).values,
 ↪  test_data['Cover_Type'].values - 1

#  Normalisation des données
scaler = StandardScaler()
X_train, X_val, X_test = scaler.fit_transform(X_train),
 ↪  scaler.transform(X_val), scaler.transform(X_test)

#  Conversion en tenseurs PyTorch
X_train_torch = torch.tensor(X_train, dtype=torch.float32,
 ↪  device=device)
y_train_torch = torch.tensor(y_train, dtype=torch.long,
 ↪  device=device)
X_val_torch = torch.tensor(X_val, dtype=torch.float32,
 ↪  device=device)
y_val_torch = torch.tensor(y_val, dtype=torch.long,
 ↪  device=device)
```

```
X_test_torch = torch.tensor(X_test, dtype=torch.float32,
 ↪  device=device)
y_test_torch = torch.tensor(y_test, dtype=torch.long,
 ↪  device=device)

#  Création des DataLoaders
batch_size = 32
train_loader = DataLoader(TensorDataset(X_train_torch,
 ↪  y_train_torch), batch_size=batch_size, shuffle=True)
val_loader = DataLoader(TensorDataset(X_val_torch, y_val_torch),
 ↪  batch_size=batch_size, shuffle=False)
test_loader = DataLoader(TensorDataset(X_test_torch,
 ↪  y_test_torch), batch_size=batch_size, shuffle=False)

#  Définition du modèle PyTorch (MLP)
class MLP(nn.Module):
    def __init__(self, input_dim, num_classes):
        super(MLP, self).__init__()
        self.fc1 = nn.Linear(input_dim, 128)
        self.relu1 = nn.ReLU()
        self.fc2 = nn.Linear(128, 64)
        self.relu2 = nn.ReLU()
        self.fc3 = nn.Linear(64, num_classes)

    def forward(self, x):
        x = self.relu1(self.fc1(x))
        x = self.relu2(self.fc2(x))
        return self.fc3(x)  # Pas de softmax ici (inclus dans
         ↪  CrossEntropyLoss)

#  Initialisation du modèle
num_features, num_classes = X_train.shape[1], len(set(y_train))
model = MLP(num_features, num_classes).to(device)

#  Optimiseur et fonction de perte
criterion = nn.CrossEntropyLoss()
optimizer = optim.Adam(model.parameters())

#  Entraînement du modèle avec sélection du meilleur nombre
 ↪  d'époques
num_epochs = 100
train_acc_list, val_acc_list = [], []
best_val_acc, best_epoch = 0, 0

for epoch in range(num_epochs):
    #  Mode entraînement
```

```
        model.train()
        correct_train, total_train = 0, 0

        for X_batch, y_batch in train_loader:
            optimizer.zero_grad()
            outputs = model(X_batch)
            loss = criterion(outputs, y_batch)
            loss.backward()
            optimizer.step()

            #  Calcul de l'accuracy sur l'entraînement
            _, predicted = torch.max(outputs, 1)
            correct_train += (predicted == y_batch).sum().item()
            total_train += y_batch.size(0)

        train_acc_list.append(correct_train / total_train)

        #  Mode validation
        model.eval()
        correct_val, total_val = 0, 0

        with torch.no_grad():
            for X_batch, y_batch in val_loader:
                outputs = model(X_batch)
                _, predicted = torch.max(outputs, 1)
                correct_val += (predicted == y_batch).sum().item()
                total_val += y_batch.size(0)

        val_accuracy = correct_val / total_val
        val_acc_list.append(val_accuracy)

        #  Sauvegarde de la meilleure époque
        if val_accuracy > best_val_acc:
            best_val_acc, best_epoch = val_accuracy, epoch + 1

#  Affichage des courbes d'entraînement
plt.figure(figsize=(8, 6))
plt.plot(range(1, num_epochs + 1), train_acc_list, label='Train
 ↪  Accuracy')
plt.plot(range(1, num_epochs + 1), val_acc_list,
 ↪  label='Validation Accuracy')
plt.axvline(best_epoch, color='r', linestyle='--', label=f'Best
 ↪  Epoch: {best_epoch}')
plt.xlabel("Époques")
plt.ylabel("Taux de bonnes prédictions")
```

```
plt.title("Optimisation du modèle de réseau de neurones
 ↪  (PyTorch)")
plt.legend()
plt.show()

#  Ré-entraîner le modèle avec le meilleur nombre d'époques
model.train()
for epoch in range(best_epoch):
    for X_batch, y_batch in train_loader:
        optimizer.zero_grad()
        outputs = model(X_batch)
        loss = criterion(outputs, y_batch)
        loss.backward()
        optimizer.step()

#  Évaluation sur l'ensemble de test
model.eval()
correct_test, total_test = 0, 0
y_test_pred_classes = []

with torch.no_grad():
    for X_batch, y_batch in test_loader:
        outputs = model(X_batch)
        _, predicted = torch.max(outputs, 1)
        y_test_pred_classes.extend(predicted.cpu().numpy())
        correct_test += (predicted == y_batch).sum().item()
        total_test += y_batch.size(0)

test_accuracy = correct_test / total_test

#  Affichage de la matrice de confusion et des métriques finales
conf_matrix = confusion_matrix(y_test, y_test_pred_classes)
print(f"\n Meilleure époque : {best_epoch} avec une précision de
 ↪  validation de {best_val_acc:.2%}")
print("\n Matrice de confusion :")
print(conf_matrix)

print("\n Taux de bien classés par classe :")
class_accuracies = conf_matrix.diagonal() /
 ↪  conf_matrix.sum(axis=1)
for i, acc in enumerate(class_accuracies, start=1):
    print(f"Classe {i} : {acc:.2%}")
print(f"\nTaux de bien classés total : {test_accuracy:.2%}")
```

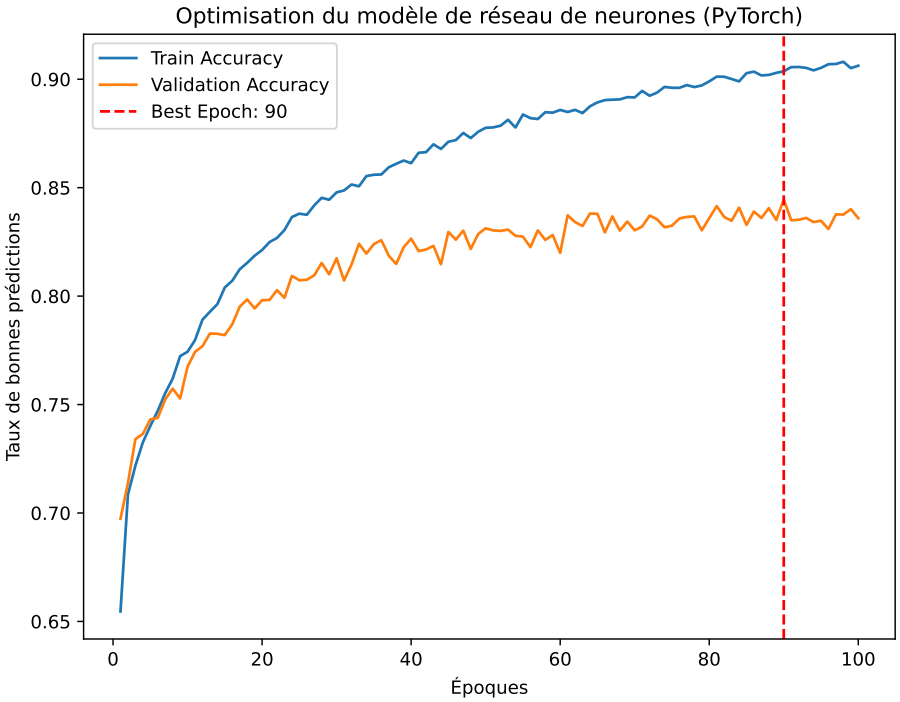


```
 Meilleure époque : 90 avec une précision de validation de 84.45%

 Matrice de confusion :
[[1740  307    2    0    9    1   60]
 [ 340 2366   26    0   63   34    4]
 [   1   12 1268   22   13  114    0]
 [   0    0   16   88    0    6    0]
 [   7   68    7    0  295    3    0]
 [   2   21  104    4    4  559    0]
 [  45    6    0    0    0    0  770]]

 Taux de bien classés par classe :
Classe 1 : 82.11%
Classe 2 : 83.52%
Classe 3 : 88.67%
Classe 4 : 80.00%
Classe 5 : 77.63%
Classe 6 : 80.55%
Classe 7 : 93.79%

Taux de bien classés total : 84.49%
```