Random Forest - Forêt Aléatoire

Théorie

La **forêt aléatoire** est un algorithme d'apprentissage supervisé basé sur un **ensemble d'arbres de décision**. Il fonctionne en combinant plusieurs arbres pour **améliorer la précision** et **réduire le risque de surapprentissage**.

Hyperparamètre utilisé

Nous allons optimiser :

- **Nombre d'arbres (`n_estimators`)** : sélectionné en fonction de la précision sur l'ensemble de validation.

Métriques d'évaluation

Nous afficherons :

- **Matrice de confusion** : récapitulant les erreurs de classification.
- **Taux de bien classés sur l'échantillon de validation** avec le meilleur hyperparamètre.
- **Taux de bien classés sur l'échantillon de test** avec ce même hyperparamètre.
- **Taux de bien classés par classe sur l'échantillon de test**.

Recherche du meilleur `n_estimators` et évaluation

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import confusion_matrix, accuracy_score
```

```python
import warnings

#  Suppression des avertissements inutiles
warnings.filterwarnings("ignore", category=UserWarning)

#  Chargement des ensembles de données
train_data = pd.read_csv('covertype_train.csv')
val_data = pd.read_csv('covertype_val.csv')
test_data = pd.read_csv('covertype_test.csv')

#  Préparation des données
X_train, y_train = train_data.drop('Cover_Type', axis=1),
 ↪  train_data['Cover_Type']
X_val, y_val = val_data.drop('Cover_Type', axis=1), val_data['Cover_Type']
X_test, y_test = test_data.drop('Cover_Type', axis=1),
 ↪  test_data['Cover_Type']

#  Recherche du meilleur hyperparamètre n_estimators
n_estimators_range = range(50, 1000, 50)
val_accuracies = []

for n in n_estimators_range:
    rf = RandomForestClassifier(n_estimators=n, random_state=42, n_jobs=-1)
    rf.fit(X_train, y_train)
    acc = accuracy_score(y_val, rf.predict(X_val))
    val_accuracies.append((n, acc))

# Sélection du meilleur nombre d'arbres
best_n, best_val_acc = max(val_accuracies, key=lambda x: x[1])


#  Affichage du graphique
plt.figure(figsize=(8, 6))
plt.plot(n_estimators_range, [acc for n, acc in val_accuracies], marker='o',
 ↪  linestyle='dashed', label="Validation")
plt.xlabel("Nombre d'arbres")
plt.ylabel("Précision sur validation")
plt.title("Impact du nombre d'arbres sur la performance de Random Forest")
plt.legend()
plt.show()

#  Modèle final avec le meilleur nombre d'arbres
```

```
final_model = RandomForestClassifier(n_estimators=best_n, random_state=42,
 ↪  n_jobs=-1)
final_model.fit(X_train, y_train)
y_test_pred = final_model.predict(X_test)

#  Matrice de confusion
conf_matrix = confusion_matrix(y_test, y_test_pred)

#  Calcul des taux de bien classés par classe
class_accuracies = conf_matrix.diagonal() / conf_matrix.sum(axis=1)
overall_test_accuracy = accuracy_score(y_test, y_test_pred)

#  Affichage des résultats
print(f"\n  Meilleur nombre d'arbres sur l'échantillon de validation :
 ↪  {best_n}")
print(f"Taux de bien classés sur l'échantillon de validation avec cet
 ↪  hyperparamètre : {best_val_acc:.2%}")
print("\n  Matrice de confusion sur l'échantillon de test, avec le meilleur
 ↪  hyperparamètre :")
print(conf_matrix)

print("\n  Taux de bien classés par classe sur l'échantillon de test, avec le
 ↪  meilleur hyperparamètre  :")
for i, acc in enumerate(class_accuracies, start=1):
    print(f"Classe {i} : {acc:.2%}")

print(f"\n  Taux de bien classés sur l'échantillon de test avec le meilleur
 ↪  hyperparamètre : {overall_test_accuracy:.2%}")
```

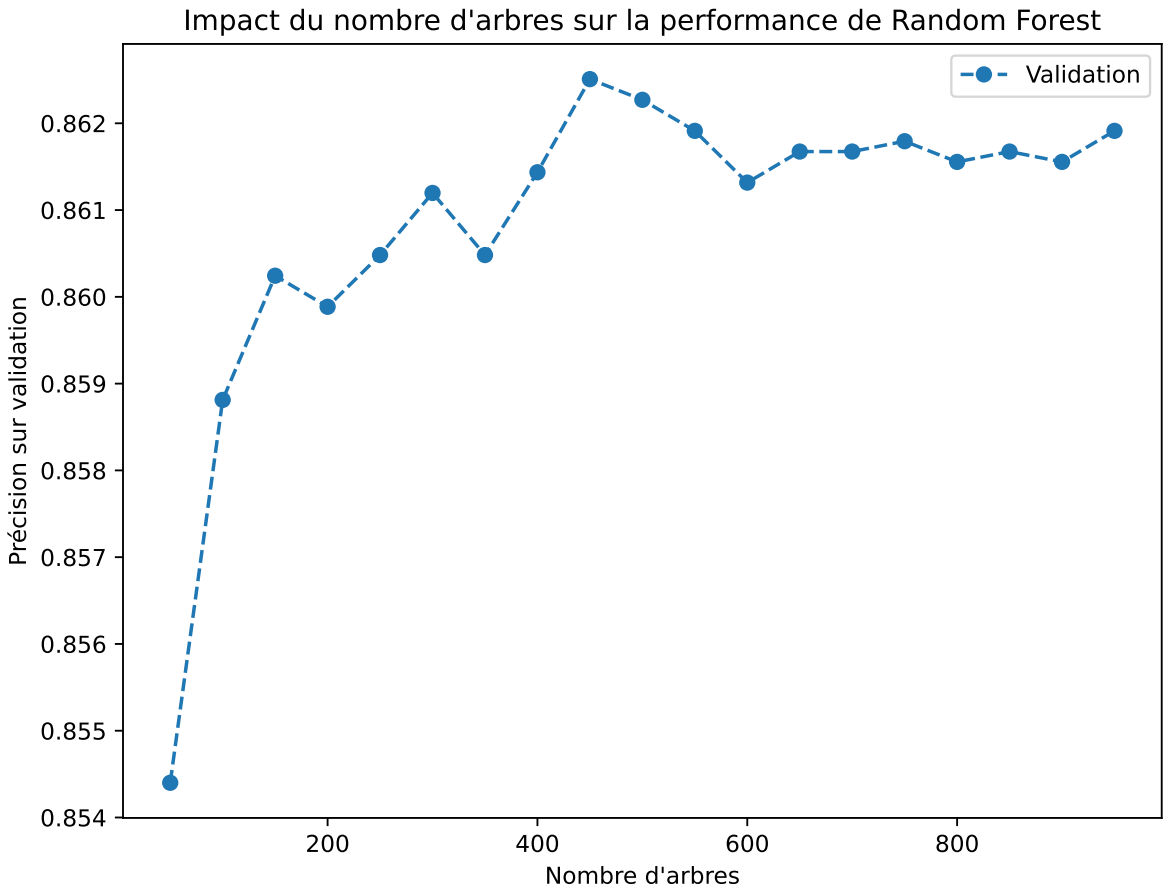


```
  Meilleur nombre d'arbres sur l’échantillon de validation : 450
Taux de bien classés sur l’échantillon de validation avec cet hyperparamètre : 86.25%

  Matrice de confusion sur l'échantillon de test, avec le meilleur hyperparamètre :
[[1753  312    0    0    5    2   47]
 [ 247 2490   40    1   20   31    4]
 [   0   15 1352   11    1   51    0]
 [   0    0   37   71    0    2    0]
 [   3   86   16    0  273    2    0]
 [   1   17  128    2    0  546    0]
 [  43    4    0    0    0    0  774]]

  Taux de bien classés par classe sur l’échantillon de test, avec le meilleur hyperparamètre
Classe 1 : 82.73%
Classe 2 : 87.89%
```

```
Classe 3 : 94.55%
Classe 4 : 64.55%
Classe 5 : 71.84%
Classe 6 : 78.67%
Classe 7 : 94.28%

 Taux de bien classés sur l'échantillon de test avec le meilleur hyperparamètre : 86.55%
```